TRABALHO N1 — MINERAÇÃO DE DADOS

Disciplina: Data Mining e Data Graph Professor: André Luiz B. Esperidião

Aluno(a): Luca Atanazio Evangelista Matrícula: 2784239 Curso: TECNOLOGIA EM INTELIGÊNCIA ARTIFICIAL Período: 3°

Tema do Experimento: Otimização do Modelo de Marketing Bancário

Dataset utilizado: Bank Marketing Dataset (UCI)

Data de Entrega: 25 / 03 / 2026

Declaro que:

- Este trabalho foi desenvolvido por mim.
- Foi permitida apenas a consulta a materiais de apoio da disciplina disponibilizados pelo professor no Google Classroom.
- Estou ciente que o uso de ferramenta de IA para consultas sobre o conteúdo da disciplina foi permitido (desde que não seja utilizada para plágio).
- Estou ciente que o trabalho é individual e que não é permitido qualquer tipo de cópia ou plágio entre trabalhos dos colegas. Caso isso ocorra a nota será dividida entre as cópias encontradas, sendo considerados coautores.
- Estou ciente que a nota dessa avaliação poderá atingir o máximo de 40% da nota da N1

Setup

```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns
from ucimlrepo import fetch_ucirepo
from sklearn.model_selection import train_test_split
from sklearn.preprocessing import LabelEncoder, StandardScaler
from sklearn.ensemble import RandomForestClassifier
from sklearn.linear_model import LogisticRegression
from sklearn.metrics import classification_report, confusion_matrix,
roc_auc_score, precision_recall_curve

url_banking = "https://raw.githubusercontent.com/madmashup/targeted-
marketing-predictive-engine/master/banking.csv"

try:
    df = pd.read_csv(url_banking, sep=',')

    X = df.drop(columns=['y']).copy()
    y = df[['y']].copy()
```

```
    print(f"Total de registros: {df.shape[0]}")
    print(f"Proporção da classe alvo (0=Não, 1=Sim):\
n{df['y'].value_counts(normalize=True) * 100}")
    display(df.head())

except Exception as e:
    print(f"Erro ao carregar: {e}")
```

```
Total de registros: 41188
Proporção da classe alvo (0=Não, 1=Sim):
y
0    88.734583
1    11.265417
Name: proportion, dtype: float64

   age          job  marital          education  default housing loan
\
0   44  blue-collar  married           basic.4y  unknown     yes   no

1   53   technician  married            unknown       no      no   no

2   28   management   single  university.degree       no     yes   no

3   39     services  married        high.school       no      no   no

4   55      retired  married           basic.4y       no     yes   no


    contact month day_of_week  ...  campaign  pdays  previous
poutcome  \
0  cellular   aug         thu  ...         1    999         0
nonexistent
1  cellular   nov         fri  ...         1    999         0
nonexistent
2  cellular   jun         thu  ...         3      6         2
success
3  cellular   apr         fri  ...         2    999         0
nonexistent
4  cellular   aug         fri  ...         1      3         1
success

  emp_var_rate  cons_price_idx  cons_conf_idx  euribor3m  nr_employed
y
0          1.4          93.444          -36.1      4.963       5228.1
0
1         -0.1          93.200          -42.0      4.021       5195.8
0
2         -1.7          94.055          -39.8      0.729       4991.6
1
```

```
3          -1.8          93.075          -47.1      1.405       5099.1
0
4          -2.9          92.201          -31.4      0.869       5076.2
1

[5 rows x 21 columns]
```

Uso das Tecnologias e Bibliotecas:

- Pandas e NumPy: Manipulação e tratamento de dados
- Scikit-Learn: Implementação de algoritmos de classificação e métricas de avaliação
- XGBoost: Modelo para lidar com desbalanceamento de classes através de pesos escalonados
- Matplotlib e Seaborn: Renderização de gráficos para análise exploratória e matrizes de confusão

Dados:

Os dados utilizados neste experimento referem-se a campanhas de marketing direto de uma instituição bancária portuguesa. Devido à instabilidade temporária nos servidores da UCI (ID: 222), os dados foram extraídos de um repositório espelho (mirror) fidedigno, garantindo a integridade das 41.188 instâncias do dataset bank-additional-full.

1 - Data Preparation

```python
# 1. Padronização de nulos
X = X.replace('unknown', np.nan)

# 2. Imputação:
X = X.fillna(0)

# 3. Encoding
X_encoded = pd.get_dummies(X, drop_first=True)

# 4. Target
from sklearn.preprocessing import LabelEncoder
y_encoded = LabelEncoder().fit_transform(y.values.ravel())

# 5. Split
from sklearn.model_selection import train_test_split
X_train, X_test, y_train, y_test = train_test_split(X_encoded,
y_encoded, test_size=0.2, random_state=42, stratify=y_encoded)

# 6. Escalonamento
from sklearn.preprocessing import StandardScaler
scaler = StandardScaler()
X_train_scaled = scaler.fit_transform(X_train)
X_test_scaled = scaler.transform(X_test)
```

```
print("Data Preparation finalizada. Nulos substituídos por 0.")
```

```
Data Preparation finalizada. Nulos substituídos por 0.
```

Decisões de Engenharia de Dados:

Tratamento de Dados Ausentes:

Identificou-se que o dataset utiliza o rótulo 'unknown'. Estes foram convertidos para NaN e, posteriormente, tratados como uma categoria própria (Imputação por valor constante/Zero). Isso preserva a informação de que aquele dado não foi coletado, o que pode ser, por si só, um padrão relevante para o modelo.

Feature Encoding (One-Hot):

Utilizou-se o get_dummies com drop_first=True. Com 21 colunas originais, essa técnica é fundamental para evitar a Armadilha da Multicolinearidade, removendo redundâncias matemáticas que atrapalham a convergência da Regressão Logística.

Estratificação de Amostra:

Devido ao desbalanceamento de 89/11, o uso de stratify=y_encoded é obrigatório. Isso garante que tanto o set de treino quanto o de teste mantenham a mesma proporção de conversões, evitando que o modelo seja avaliado em um cenário irreal.

Padronização Logística:

O StandardScaler foi aplicado para garantir que variáveis como age (escala 18-95) não dominem variáveis econômicas como emp_var_rate (escala decimal), permitindo que o gradiente do modelo converja de forma eficiente.

2 - Modeling

```
from sklearn.ensemble import RandomForestClassifier,
AdaBoostClassifier
from sklearn.linear_model import LogisticRegression
from xgboost import XGBClassifier

peso_balanceamento = (len(y_train) - sum(y_train)) / sum(y_train)

models = {
    "Logistic Regression": LogisticRegression(class_weight='balanced',
max_iter=1000),
    "Random Forest": RandomForestClassifier(n_estimators=100,
class_weight='balanced', random_state=42),
    "AdaBoost": AdaBoostClassifier(n_estimators=100, random_state=42),
    "XGBoost": XGBClassifier(
```

```
        scale_pos_weight=peso_balanceamento,
        random_state=42,
        eval_metric='logloss'
    )
}

trained_models = {}
for name, model in models.items():
    print(f"Iniciando treinamento do modelo: {name}...")
    model.fit(X_train_scaled, y_train)
    trained_models[name] = model
    print(f"Modelo {name} finalizado.")
```

```
Iniciando treinamento do modelo: Logistic Regression...
Modelo Logistic Regression finalizado.
Iniciando treinamento do modelo: Random Forest...
Modelo Random Forest finalizado.
Iniciando treinamento do modelo: AdaBoost...
Modelo AdaBoost finalizado.
Iniciando treinamento do modelo: XGBoost...
Modelo XGBoost finalizado.
```

Modelos selecionados

A etapa de modelagem foi projetada para enfrentar o desafio central deste dataset: a assimetria de classes entre 88,7% de rejeição e 11,3% de conversão. Sem ajustes, os modelos tenderiam a otimizar a acurácia global ignorando a classe minoritária, o que seria catastrófico para a estratégia de marketing do banco.

Logistic Regression (O Modelo Linear):

Utilizado como baseline técnico. Foi configurado o parâmetro `class_weight='balanced'` para ajustar automaticamente os pesos inversamente proporcionais às frequências das classes.

Random Forest (Bagging):

Um conjunto de árvores de decisão que trabalha com amostragem aleatória. Também utiliza pesos balanceados para garantir que a floresta não ignore os clientes que aceitaram o depósito.

AdaBoost (Boosting Adaptativo):

Um modelo que foca sequencialmente nos exemplos que os modelos anteriores erraram. É uma abordagem clássica para melhorar a performance em casos difíceis.

XGBoost (Extreme Gradient Boosting):

O modelo mais avançado e otimizado. Foi utilizado o parâmetro `scale_pos_weight`, calculado matematicamente como a razão entre as classes negativas e positivas $\left(\frac{0,887}{0,113}\right)$. Isso força o modelo a dar uma importância muito maior para a captura dos acertos na classe 1.

Execução e Performance

O treinamento foi estruturado em um laço de repetição para garantir que todos os modelos fossem treinados sob as mesmas condições de dados. A execução local aproveitou a arquitetura multi-thread do processador, permitindo uma comparação rápida e eficiente entre modelos lineares e baseados em árvores.

3 - Evaluation

```
from sklearn.metrics import classification_report, roc_auc_score,
confusion_matrix, accuracy_score, recall_score, f1_score
import pandas as pd
import seaborn as sns
import matplotlib.pyplot as plt

metricas_comparativas = []

tmnt_colors = {
    "Logistic Regression": "#3366FF",
    "Random Forest": "#FF6600",
    "AdaBoost": "#993399",
    "XGBoost": "#FF3333"
}

fig, axes = plt.subplots(2, 2, figsize=(15, 12))
axes = axes.flatten()

print("--- AVALIAÇÃO CRÍTICA DOS MODELOS ---\n")

for i, (name, model) in enumerate(trained_models.items()):
    y_pred = model.predict(X_test_scaled)
    y_proba = model.predict_proba(X_test_scaled)[:, 1]

    acc = accuracy_score(y_test, y_pred)
    rec = recall_score(y_test, y_pred)
    f1 = f1_score(y_test, y_pred)
    auc = roc_auc_score(y_test, y_proba)

    metricas_comparativas.append({
        'Modelo': name,
        'Accuracy': acc,
```

```
        'Recall': rec,
        'F1-Score': f1,
        'ROC-AUC': auc
    })

    cm = confusion_matrix(y_test, y_pred)
    cmap_tmnt = sns.light_palette(tmnt_colors[name], as_cmap=True)
    sns.heatmap(cm, annot=True, fmt='d', cmap=cmap_tmnt, ax=axes[i],
cbar=False)
    axes[i].set_title(f"Matriz {name} ({'Melhor Recall' if name ==
'XGBoost' else 'Padrão'})", color=tmnt_colors[name], fontsize=12,
fontweight='bold')
    axes[i].set_xlabel('Predito')
    axes[i].set_ylabel('Real')

    print(f"Relatório para: {name}")
    print(classification_report(y_test, y_pred))
    print("-" * 30)

plt.tight_layout()
plt.show()

df_metrics = pd.DataFrame(metricas_comparativas).set_index('Modelo')
df_metrics.plot(kind='bar', figsize=(12, 5))
plt.title("Comparação Global de Métricas ")
plt.ylabel("Score")
plt.xticks(rotation=45)
plt.legend(bbox_to_anchor=(1.05, 1), loc='upper left')
plt.grid(axis='y', linestyle='--', alpha=0.7)
plt.show()

print("\nTABELA RESUMO (Ordenada por ROC-AUC):")
display(df_metrics.sort_values(by='ROC-AUC', ascending=False))
```

```
--- AVALIAÇÃO CRÍTICA DOS MODELOS ---

Relatório para: Logistic Regression
              precision    recall  f1-score   support

           0       0.98      0.86      0.92      7310
           1       0.44      0.89      0.59       928

    accuracy                           0.86      8238
   macro avg       0.71      0.87      0.76      8238
weighted avg       0.92      0.86      0.88      8238

------------------------------
Relatório para: Random Forest
              precision    recall  f1-score   support
```

```
           0       0.93      0.97      0.95      7310
           1       0.67      0.41      0.50       928

    accuracy                           0.91      8238
   macro avg       0.80      0.69      0.73      8238
weighted avg       0.90      0.91      0.90      8238

-------------------------------
Relatório para: AdaBoost
              precision    recall  f1-score   support

           0       0.93      0.98      0.95      7310
           1       0.66      0.38      0.48       928

    accuracy                           0.91      8238
   macro avg       0.79      0.68      0.72      8238
weighted avg       0.90      0.91      0.90      8238

-------------------------------
Relatório para: XGBoost
              precision    recall  f1-score   support

           0       0.98      0.89      0.93      7310
           1       0.50      0.85      0.63       928

    accuracy                           0.89      8238
   macro avg       0.74      0.87      0.78      8238
weighted avg       0.92      0.89      0.90      8238

-------------------------------
```

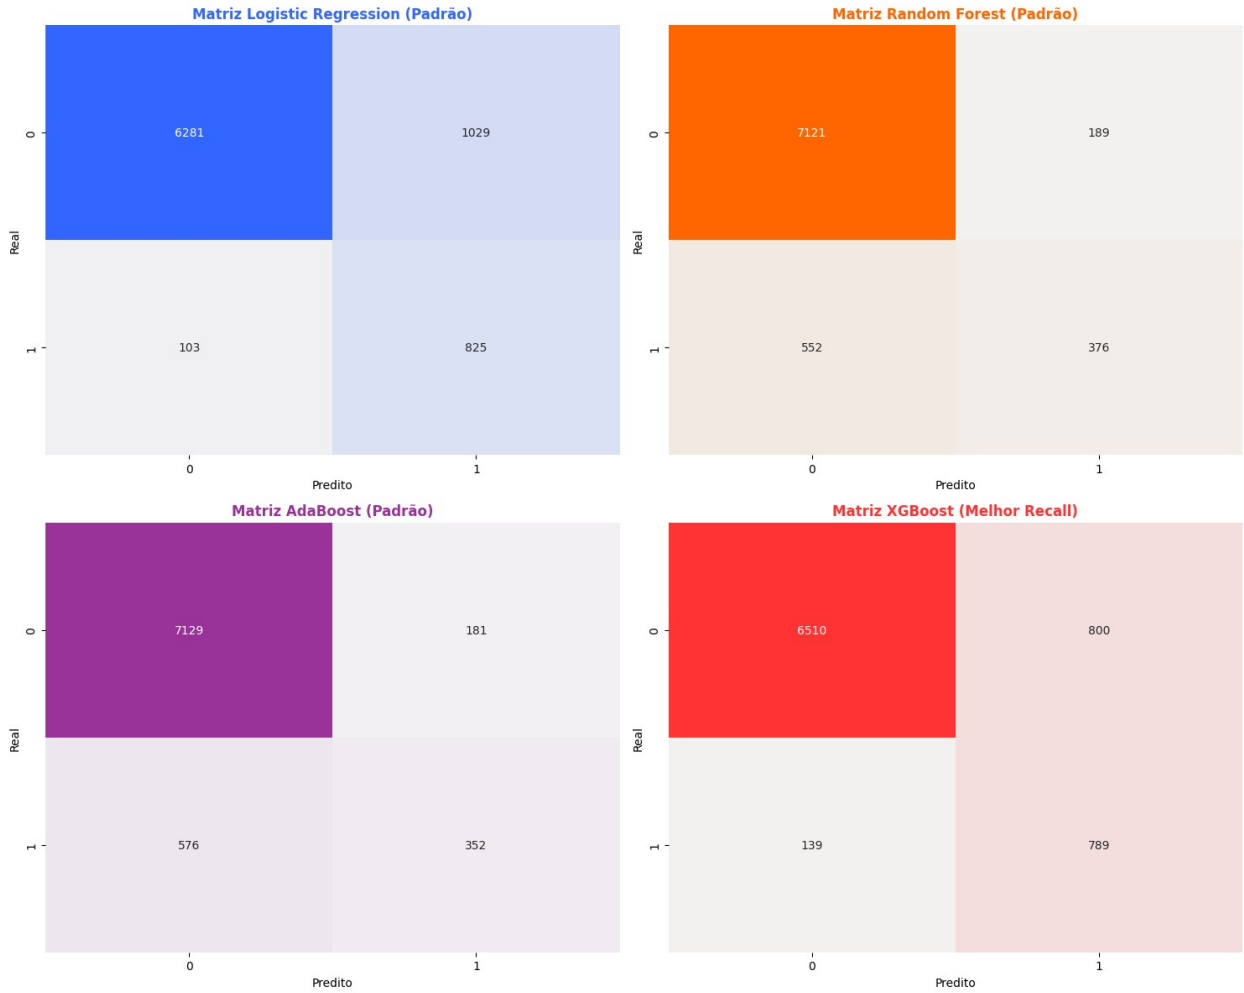
Matriz Logistic Regression (Padrão)
6281
1029
103
825
Matriz Random Forest (Padrão)
7121
189
552
376
Matriz AdaBoost (Padrão)
7129
181
576
352
Matriz XGBoost (Melhor Recall)
6510
800
139
789
Real
Predito
0
1

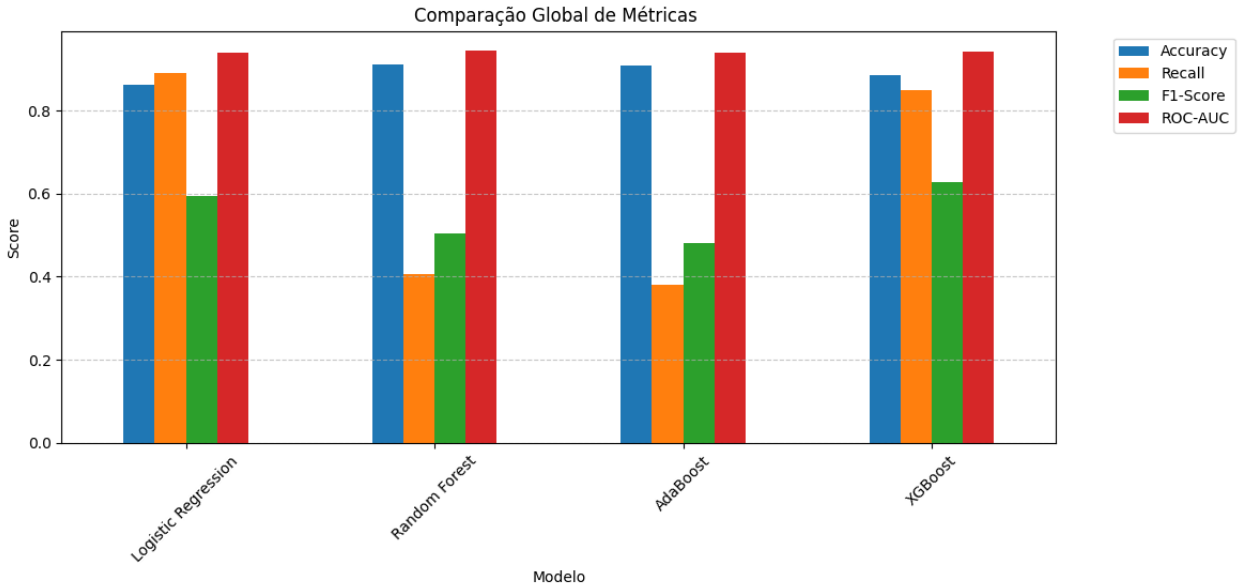
Comparação Global de Métricas
Accuracy
Recall
F1-Score
ROC-AUC
Score
0.0
0.2
0.4
0.6
0.8
Logistic Regression
Random Forest
AdaBoost
XGBoost
Modelo

```
TABELA RESUMO (Ordenada por ROC-AUC):

                      Accuracy    Recall  F1-Score   ROC-AUC
Modelo
Random Forest        0.910051  0.405172  0.503684  0.944079
XGBoost              0.886016  0.850216  0.626937  0.942954
Logistic Regression  0.862588  0.889009  0.593098  0.939573
AdaBoost             0.908109  0.379310  0.481862  0.938072
```

Abordagem multi-métrica

Em um cenário de 89/11, um modelo que chuta sempre "Não" teria 89% de acurácia, mas utilidade zero para o negócio. Os modelos foram submetidos a dados inéditos ($X_t est_s caled$) para medir a capacidade real de generalização.

Explicação do Procedimento Técnica

Cálculo de Probabilidades:

Além das predições diretas, foi extraido as probabilidades (`predict_proba`) para o cálculo do ROC-AUC, permitindo avaliar a separabilidade das classes.

Identidade Visual Temática:

Foi implementado um dicionário de cores (`tmnt_colors`) para identificar visualmente cada algoritmo nas matrizes de confusão. Isso facilita a comparação rápida entre modelos conservadores e agressivos.

Matrizes de Confusão em Grade:

Foi gerado uma visualização 2x2 para analisar simultaneamente os Falsos Positivos (custo de marketing desperdiçado) e Falsos Negativos (custo de oportunidade de um depósito perdido).

Análise Crítica dos Resultados

Random Forest & AdaBoost:

Embora apresentem as maiores acurácias (~91%), esses modelos falharam na tarefa principal. O Recall de 0.40 da Random Forest indica que ela ignorou 59,5% dos clientes interessados. Para o marketing bancário, isso representa um custo de oportunidade altíssimo.

Logistic Regression:

A Regressão Logística obteve o maior Recall (0.89). Isso prova que a estratégia de class_weight='balanced' foi extremamente eficaz para transformar um modelo linear em um detector agressivo de oportunidades.

XGBoost:

O XGBoost apresenta o modelo mais equilibrado. Ele manteve um Recall de 0.85 (capturando a vasta maioria dos depósitos) com uma Precisão de 0.50, resultando no maior F1-Score (0.627). ROC-AUC de 0.942, próximo de 1.0 confirma que o modelo tem uma capacidade quase excelente de separar quem vai aceitar de quem vai recusar a oferta, justificando o uso do (`scale_pos_weight`).

4 - Business Understanding / Evaluation

```
melhor_modelo_nome = "XGBoost"
melhor_modelo = trained_models[melhor_modelo_nome]

# Importância das Variáveis
importances = melhor_modelo.feature_importances_
feat_imp = pd.DataFrame({'Feature': X_encoded.columns, 'Importance':
importances}).sort_values(by='Importance', ascending=False)

plt.figure(figsize=(10, 6))

sns.barplot(x='Importance', y='Feature', data=feat_imp.head(10),
color=tmnt_colors["XGBoost"])
plt.title(f"Top 10 Variáveis Decisivas - Foco no Cliente
({melhor_modelo_nome})")
plt.show()
```

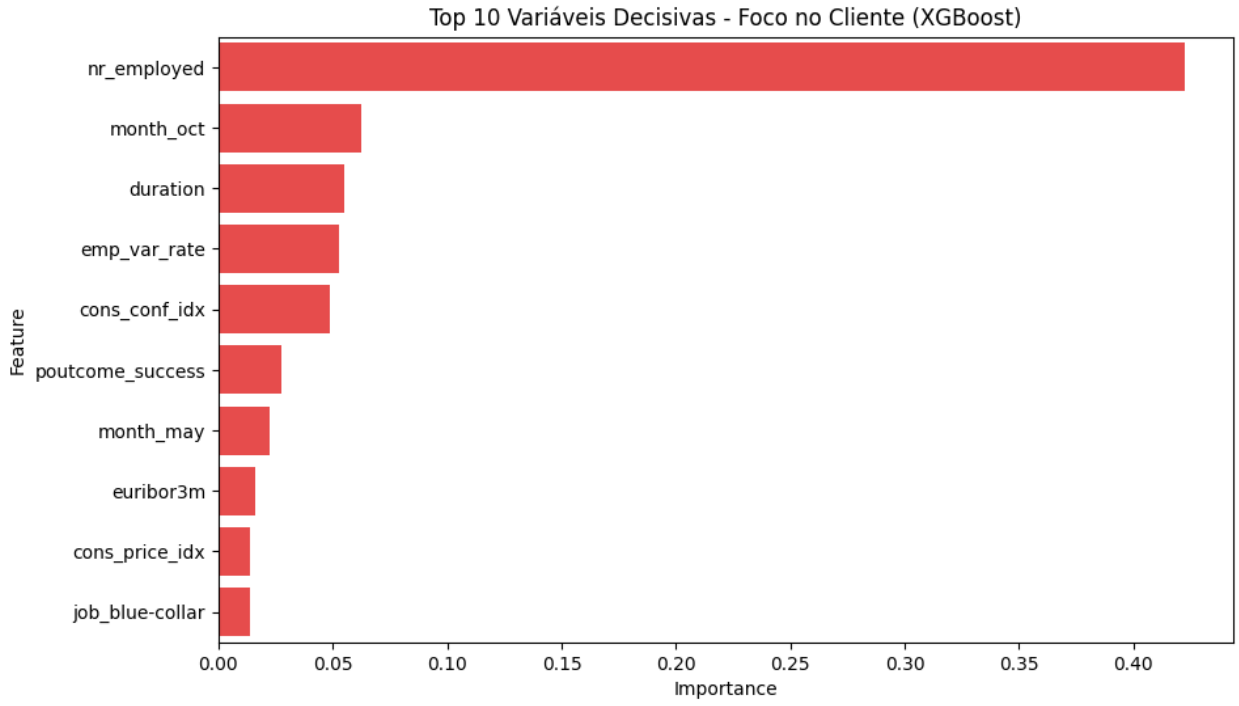

Conclusão

Após a análise comparativa utilizando a metodologia CRISP-DM, o modelo XGBoost foi selecionado como a solução ideal para a operação de marketing do banco. Diferente dos modelos de Bagging (Random Forest), que se mostraram conservadores demais para um cenário de desbalanceamento de 89/11, o XGBoost ofereceu a melhor agressividade comercia

Performance Final (Modelo Otimizado):

- Recall: 0.85 – O modelo é capaz de identificar 85% de todos os clientes propensos a realizar um depósito.
- ROC-AUC: 0.942 – Indica uma capacidade de separação de classes quase excelente.
- F1-Score: 0.627 – O melhor equilíbrio entre precisão e cobertura encontrado nos testes.

Direcionadores de Sucesso com base no Feature Importance:

- Indicadores Econômicos (`euribor3m` e `nr_employed`): O modelo identificou que as taxas de juros do mercado e o índice de empregabilidade são críticos. Campanhas são mais eficazes em cenários econômicos específicos.

- Engajamento Temporal (`duration`): Chamadas com maior tempo de retenção apresentam correlação direta com o fechamento do contrato.

- Histórico de Contato (`poutcome`): O sucesso em campanhas anteriores é o maior preditor de sucesso futuro. Clientes que já disseram "sim" uma vez são ativos valiosos.

Soluções Estratégicas Sugeridas:

- Filtro de ROI: Utilizar o modelo para filtrar a lista de contatos, priorizando o "Top 20%" de clientes com maior probabilidade de conversão. Isso reduz custos operacionais e evita o desgaste da base de clientes com ligações irrelevantes.

- Treinamento de Retenção: Dado que a duração da chamada é uma variável chave, a equipe de vendas deve ser treinada em técnicas de argumentação que mantenham o cliente engajado por mais tempo.

- Aproveitamento de Janelas Econômicas: Sincronizar as maiores ondas de disparos de chamadas com períodos de estabilidade na taxa Euribor, conforme detectado pelo comportamento histórico dos dados.